Московский государственный технический университет им. Н.Э. Баумана Факультет «Информатика и системы управления» Кафедра «Системы обработки информации и управления»



Отчёт

"Методы машинного обучения"

Лабораторная работа № 1

"Разведочный анализ данных. Исследование и визуализация данных"

ИСПОЛНИТЕЛЬ:
Студент группы ИУ5-21М
Коростелёв В. М.
ПРЕПОДАВАТЕЛЬ:
Гапанюк Ю. Е.

Москва – 2019

Задание

Выбрать набор данных (датасет). Создать ноутбук, который содержит следующие разделы: Текстовое описание выбранного Вами набора данных. Основные характеристики датасета. Визуальное исследование датасета. Информация о корреляции признаков. Сформировать отчет и разместить его в своем репозитории на github.

```
In [1]:
         import numpy as np
         import pandas as pd
         import seaborn as sns
         import matplotlib.pyplot as plt
         %matplotlib inline
         sns.set(style="ticks")
In [2]:
         data = pd.read_csv('auto.csv', sep=",")
In [3]:
         data.head()
Out[3]:
                                                     num-
                       normalized-
                                                               body-
                                                                       drive-
                                                                              engine-
                                                                                      wheel-
             symboling
                                    make aspiration
                                                       of-
                                                                                               length ...
                                                                             location
                            losses
                                                                style
                                                                      wheels
                                                                                        base
                                                     doors
                                     alfa-
          0
                     3
                                                                                             0.811148
                              122
                                                std
                                                           convertible
                                                                         rwd
                                                                                 front
                                                                                        88.6
                                                       two
                                   romero
                                     alfa-
                     3
                                                                                             0.811148
          1
                              122
                                                std
                                                       two
                                                           convertible
                                                                         rwd
                                                                                 front
                                                                                        88.6
                                     alfa-
          2
                              122
                                                std
                                                       two
                                                            hatchback
                                                                         rwd
                                                                                 front
                                                                                        94.5
                                                                                             0.822681
                                   romero
                     2
          3
                              164
                                     audi
                                                std
                                                       four
                                                               sedan
                                                                         fwd
                                                                                 front
                                                                                        99.8
                                                                                             0.848630
                     2
                              164
                                     audi
                                                std
                                                       four
                                                               sedan
                                                                        4wd
                                                                                 front
                                                                                        99.4
                                                                                             0.848630
         5 rows × 29 columns
In [4]:
         data.shape
Out[4]: (201, 29)
In [5]:
         total_count = data.shape[0]
         print('Bcero ctpok: {}'.format(total_count))
         Всего строк: 201
In [6]:
         data.columns
'width', 'height', 'curb-weight', 'engine-type', 'num-of-cylinders',
                 'engine-size', 'fuel-system', 'bore', 'stroke', 'compression-ratio',
'horsepower', 'peak-rpm', 'city-mpg', 'highway-mpg', 'price',
                 'city-L/100km', 'horsepower-binned', 'diesel', 'gas'],
                dtype='object')
```

In [7]: data.dtypes Out[7]: symboling int64 normalized-losses int64 make object aspiration object num-of-doors object body-style object drive-wheels object engine-location object wheel-base float64 float64 length width float64 height float64 curb-weight int64 object engine-type num-of-cylinders object engine-size int64 fuel-system object bore float64 stroke float64 compression-ratio float64 float64 horsepower float64 peak-rpm city-mpg int64 highway-mpg int64 price float64 city-L/100km float64 horsepower-binned object diesel int64 gas int64 dtype: object

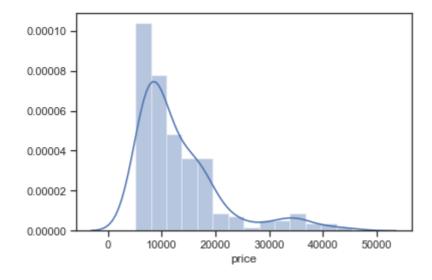
In [8]: data.describe()

Out[8]:

	symboling	normalized- losses	wheel- base	length	width	height	curb-weight	engine- size
count	201.000000	201.00000	201.000000	201.000000	201.000000	201.000000	201.000000	201.000000
mean	0.840796	122.00000	98.797015	0.837102	0.915126	53.766667	2555.666667	126.875622
std	1.254802	31.99625	6.066366	0.059213	0.029187	2.447822	517.296727	41.546834
min	-2.000000	65.00000	86.600000	0.678039	0.837500	47.800000	1488.000000	61.000000
25%	0.000000	101.00000	94.500000	0.801538	0.890278	52.000000	2169.000000	98.000000
50%	1.000000	122.00000	97.000000	0.832292	0.909722	54.100000	2414.000000	120.000000
75%	2.000000	137.00000	102.400000	0.881788	0.925000	55.500000	2926.000000	141.000000
max	3.000000	256.00000	120.900000	1.000000	1.000000	59.800000	4066.000000	326.000000
4								>

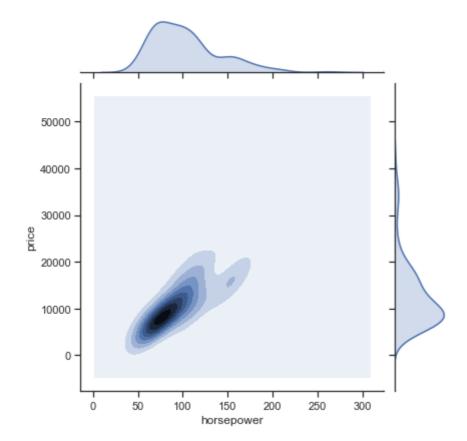
In [9]: sns.distplot(data['price'])

Out[9]: <matplotlib.axes._subplots.AxesSubplot at 0x2b5dce67208>

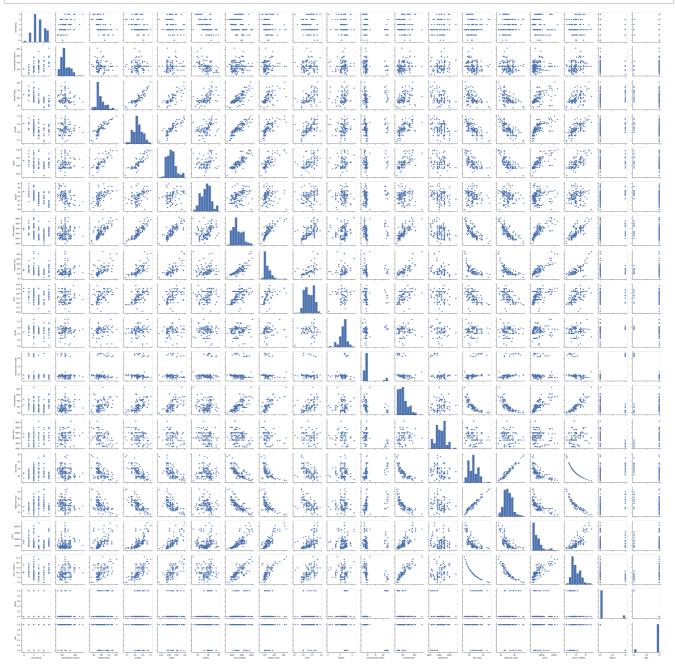


In [10]: sns.jointplot(x='horsepower', y='price', data=data, kind="kde")

Out[10]: <seaborn.axisgrid.JointGrid at 0x2b5deeaecc0>



In [11]: import warnings
warnings.filterwarnings('ignore')
sns.pairplot(data, plot_kws=dict(linewidth=0));



In [12]: data.corr()

Out[12]:

	symboling	normalized- losses	wheel- base	length	width	height	curb- weight	engine- size	
symboling	1.000000	0.466264	-0.535987	-0.365404	-0.242423	-0.550160	-0.233118	-0.110581	_
normalized- losses	0.466264	1.000000	-0.056661	0.019424	0.086802	-0.373737	0.099404	0.112360	-
wheel-base	-0.535987	-0.056661	1.000000	0.876024	0.814507	0.590742	0.782097	0.572027	
length	-0.365404	0.019424	0.876024	1.000000	0.857170	0.492063	0.880665	0.685025	
width	-0.242423	0.086802	0.814507	0.857170	1.000000	0.306002	0.866201	0.729436	
height	-0.550160	-0.373737	0.590742	0.492063	0.306002	1.000000	0.307581	0.074694	
curb-weight	-0.233118	0.099404	0.782097	0.880665	0.866201	0.307581	1.000000	0.849072	
engine-size	-0.110581	0.112360	0.572027	0.685025	0.729436	0.074694	0.849072	1.000000	
bore	-0.140019	-0.029862	0.493244	0.608971	0.544885	0.180449	0.644060	0.572609	
stroke	-0.008245	0.055563	0.158502	0.124139	0.188829	-0.062704	0.167562	0.209523	-
compression- ratio	-0.182196	-0.114713	0.250313	0.159733	0.189867	0.259737	0.156433	0.028889	
horsepower	0.075819	0.217299	0.371147	0.579821	0.615077	-0.087027	0.757976	0.822676	
peak-rpm	0.279740	0.239543	-0.360305	-0.285970	-0.245800	-0.309974	-0.279361	-0.256733	-
city-mpg	-0.035527	-0.225016	-0.470606	-0.665192	-0.633531	-0.049800	-0.749543	-0.650546	-
highway-mpg	0.036233	-0.181877	-0.543304	-0.698142	-0.680635	-0.104812	-0.794889	-0.679571	-
price	-0.082391	0.133999	0.584642	0.690628	0.751265	0.135486	0.834415	0.872335	
city-L/100km	0.066171	0.238567	0.476153	0.657373	0.673363	0.003811	0.785353	0.745059	
diesel	-0.196735	-0.101546	0.307237	0.211187	0.244356	0.281578	0.221046	0.070779	
gas	0.196735	0.101546	-0.307237	-0.211187	-0.244356	-0.281578	-0.221046	-0.070779	-

In [13]: sns.heatmap(data.corr())

Out[13]: <matplotlib.axes._subplots.AxesSubplot at 0x2b5e9f367b8>

